

Sprint 1 - G11 | LLMOps / AgentOps

CI/CD e ciclo de vida para aplicações baseadas em LLMs

1. Definição do tema

O grupo estudará LLMOps/AgentOps, área que aplica práticas de DevOps, MLOps e engenharia de software ao ciclo de vida de aplicações com LLMs e agentes. O foco será CI/CD para LLMs, considerando versionamento de prompts, modelos, ferramentas e avaliações automatizadas antes de merge ou deploy.

2. Problema e motivação

Aplicações com LLMs são não determinísticas: pequenas alterações em prompt, modelo ou configuração podem mudar respostas, formato, segurança e qualidade sem serem detectadas por testes tradicionais. Isso gera regressões silenciosas, dificuldade de auditoria e risco em produção. A motivação é mostrar como evals automatizadas podem funcionar como testes de regressão para apoiar decisões objetivas de integração.

3. Escopo do mini-projeto

Será desenvolvido o PromptGuard CI Lite, um protótipo demonstrativo de pipeline para avaliar alterações em uma aplicação simples de FAQ acadêmico ou atendimento estudantil. O repositório terá 20 a 30 casos fixos de avaliação com entrada, resposta esperada e critérios de acerto. Em cada Pull Request que altere prompt, modelo, configuração ou base de testes, o GitHub Actions executará o Promptfoo, comparará a taxa de acerto com uma linha de base e bloqueará o merge se houver regressão superior a 10%. O grupo também entregará um dashboard HTML simples mostrando aprovados, reprovados, exemplos de regressão e decisão final do pipeline.

4. Stack técnica

- Promptfoo: execução das evals, comparação de resultados e detecção de regressões.
- GitHub Actions: automação do pipeline em Pull Requests.
- Python: consolidação dos resultados e geração dos dados do dashboard.
- HTML/CSS: dashboard simples para visualização das regressões.
- Git/GitHub: versionamento de prompts, configurações, avaliações e workflow.

5. Divisão de responsabilidades

Integrante	Responsabilidade
João Victor De Mauro Vasconcellos	Pesquisa e fundamentação sobre LLMOps/AgentOps, CI/CD, evals e dívida técnica em ML.
Víctor Caproni	Dataset de avaliação: definição dos 20-30 casos, critérios de acerto e linha de base.
João Vítor Ferreira Malaquias	Implementação do pipeline com Promptfoo, GitHub Actions e regra de bloqueio por regressão maior que 10%.
Tiago Toi	Dashboard HTML, comparação entre versões, visualização das regressões e apoio ao relatório.
Vítor Carnevali	Revisão do painel A1, validação final do conteúdo.

6. Critério de sucesso

Na Sprint 2, o repositório deverá executar as avaliações localmente e no GitHub Actions, exibindo casos aprovados/reprovados e uma decisão objetiva de merge. Na Sprint 3, deverá existir uma comparação entre uma versão boa e uma versão com regressão, comprovando o bloqueio do pipeline e a utilidade do dashboard.



Referências

- [1] PROMPTFOO. CI/CD Integration for LLM Evaluation and Security. Promptfoo Documentation. Disponível em: <https://www.promptfoo.dev/docs/integrations/ci-cd/>. Acesso em: 20 maio 2026.
- [2] ANTHROPIC. Demystifying evals for AI agents. Anthropic Engineering. Disponível em: <https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents>. Acesso em: 20 maio 2026.
- [3] SCULLEY, D. et al. Hidden Technical Debt in Machine Learning Systems. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS 28, 2015. Disponível em: <https://papers.nips.cc/paper/5656-hidden-technical-debt-in-machine-learning-systems>.
- [4] GITHUB. Workflow syntax for GitHub Actions. GitHub Docs. Disponível em: <https://docs.github.com/actions/reference/workflows-and-actions/workflow-syntax>. Acesso em: 20 maio 2026.
- [5] OPENAI. Evals: framework for evaluating LLMs and LLM systems. GitHub repository. Disponível em: <https://github.com/openai/evals>. Acesso em: 20 maio 2026.
- [6] LANGCHAIN. LangSmith Evaluation. LangChain Documentation. Disponível em: <https://docs.langchain.com/langsmith/evaluation>. Acesso em: 20 maio 2026.
- [7] BRECK, E. et al. The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction. In: 2017 IEEE INTERNATIONAL CONFERENCE ON BIG DATA, 2017. Disponível em: <https://research.google.com/pubs/archive/aad9f93b86b7addfea4c419b9100c6cdd26cacea.pdf>.
- [8] ZINKEVICH, M. Rules of Machine Learning: Best Practices for ML Engineering. Google, 2017. Disponível em: https://martin.zinkevich.org/rules_of_ml/rules_of_ml.pdf.