

PromptGuard CI Lite

Regression eval em CI/CD para proteger prompts e evitar regressões em aplicações LLM.



Repositório GitHub
escaneie o QR code

STATUS	ACURÁCIA ATUAL	BASELINE	REGRESSÃO	CASOS OK
APROVADO	100%	100%	0%	20/20

1. Contexto

Aplicações com LLM mudam rápido: pequenas alterações de prompt, regra ou dataset podem melhorar uma resposta e quebrar outra.

O projeto simula uma esteira de CI/CD que executa avaliações automáticas antes do merge, usando casos versionados e uma linha de base.

Objetivo do protótipo: demonstrar o ciclo de vida LLMOps/AgentOps com foco em controle de regressão, rastreabilidade e decisão automática no pipeline.

Escopo: classificador determinístico de perguntas gerais, sem dependência de API externa, pronto para rodar localmente e no GitHub Actions.

2. Conceitos

LLMOps aplica práticas de engenharia, observabilidade e CI/CD ao ciclo de vida de sistemas com LLM.

Regression eval compara a versão atual com uma baseline. Se a queda de desempenho ultrapassar o limite, o pipeline bloqueia a entrega.

Categorias avaliadas:

- GEOGRAFIA, MATEMÁTICA, TECNOLOGIA
- HISTÓRIA, CIÊNCIAS, FORA_ESCOPO

Regra de gate: `baseline_accuracy - current_accuracy > 0,10` bloqueia o merge.

3. Estado da arte

Ferramentas de eval, como Promptfoo, ajudam a testar prompts com casos padronizados, assertions e relatórios.


Boas práticas usadas no projeto:

- prompts e datasets versionados no Git
- baseline explícita para comparação
- execução em Pull Request
- dashboard HTML para análise dos resultados

Distribuição dos casos de avaliação:

4	4	4	4	2	2
GEO	MAT	TEC	HIST	CIÊN	F.ESC

4. Arquitetura



- Componentes do repositório:**
- prompts/ e data/eval_cases.json: prompt e testes versionados
 - baseline.json e reports/: comparação e dashboard

5. Demo

Execução local:

```
python promptguard.py evaluate
```

Saída esperada da avaliação:

```
PromptGuard CI Lite: 20/20 casos aprovados
Baseline: 100% | Atual: 100% | Regressão: 0%
Status: PASSED
```

No Pull Request, o GitHub Actions instala Python 3.11, roda a avaliação local e em seguida executa o Promptfoo com Node.js 20.

Entregáveis gerados: results.json e dashboard.html.

6. Discussão

Resultados quantitativos do protótipo:

- 20 casos avaliados; 20 aprovados; 0 falhas
- acurácia atual: 100%
- baseline: 100%
- regressão calculada: 0%
- limite máximo aceito: 10%

Ponto forte: o pipeline transforma qualidade de prompt em critério objetivo de entrega.

Limitação: o provedor é determinístico e simplificado; em LLMs reais seria necessário ampliar o dataset, testar respostas abertas e monitorar custo, latência e segurança.

Próximos passos: incluir mais casos, testes adversariais e histórico de regressões por versão.